



UTN.BA

UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Tecnologías para la Automatización - TP Integral

Control de latencia de un Microservicio

Curso K4052 - 1° Cuatrimestre 2026

Alumno: Franco Alessandro Marsico

Profesor: Drando. Omar Civalé

Fecha de entrega: 11/07/2026

Pautas para el desarrollo del Trabajo Final de Tecnologías de Automatización

1. Objeto de este documento

- Proporcionar una guía de orientación para el desarrollo del **Trabajo de Integración** de la materia, en lo concerniente al bloque temático de la Teoría de Control (oportunamente explicitado en sucesivas clases desde el inicio de la cursada).
- Contiene el propósito, objetivos del trabajo, las pautas a seguir y las recomendaciones correspondientes.

2. Propósito

- Aplicar **la totalidad** de los conceptos fundamentales de la Teoría de Control a un sistema elegido por cada equipo de trabajo.

3. Objetivos Generales

- Seleccionar un sistema de control aplicado a una solución tecnológica (**preferentemente, del área de Sistemas de la Información**). Es importante destacar que **el sistema elegido deberá existir en el mercado**, siendo utilizado a modo de modelo de análisis.
- Fundamentar el sistema propuesto utilizando, a modo de marco teórico, los conceptos, fundamentos, enfoques y estrategias de la Ingeniería de Control.
- Aplicar diferentes técnicas o herramientas informáticas, en forma creativa, para realizar gráficos, modelos, cuadros comparativos, y, en general para expresar el análisis del problema y la solución propuesta.
- Basar el desarrollo del trabajo en el análisis y criterio individual de los integrantes del equipo, de manera tal de elaborar una producción propia basada en los aspectos descriptivos, funcionales y prospectivos del sistema en cuestión.

4. Pautas

- **Desarrollo del trabajo**

El trabajo de investigación será desarrollado por equipos de no más de dos integrantes.

La fecha de entrega del Trabajo Final será informada mediante la plataforma del webcampus. Esta fecha permitirá la corrección del mismo antes de la primera fecha de llamado a final.

Para el caso de que el TP no sea aprobado y requiera de correcciones y/o mayor desarrollo, o no haya sido presentado hasta la fecha indicada, **se estipulará una nueva fecha tope de entrega mediante el mismo procedimiento.**

Una vez aprobado el TP, y en caso de tener cumplimentadas la totalidad de las actividades obligatorias pautadas, el alumno estará en condiciones de firmar la materia.

La entrega se realizará en formato de archivo PDF por cada alumno en el web campus del curso (en el sitio dedicado a tal efecto).

En cada trabajo se incluirá en la carátula el listado de integrantes del grupo.

Pueden realizarse consultas durante el período de desarrollo.

- **Composición del Trabajo de Investigación**

El trabajo, desde el punto de vista formal, estará compuesto de las siguientes partes:

- ✓ **Carátula:** incluye el título del tema, nombre y apellido de los integrantes del equipo de trabajo, la comisión, el nombre y apellido del profesor, la fecha de entrega.
- ✓ **Copia** del presente documento.
- ✓ **Índice:** contenido del documento elaborado por el equipo.
- ✓ **Introducción:** se referirá al “segmento / mercado” en que se encuadra el trabajo (por ejemplo, “...el control del riego y la fertilización de una plantación...”).
- ✓ **Objetivos:** cuales son los objetivos de control a ser alcanzados y cual es la solución que se plantea u ofrece.
- ✓ **Alcance:** definir la estructura del sistema considerado, describiendo e identificando clara y explícitamente las diferentes funcionalidades correspondientes al mismo (por ejemplo: contexto; tipo de carga a considerar; puntos de interconexión con el mundo exterior; tipos de transductores; variables que se desea controlar, tipos de unidades y rangos de entradas y salidas, amplificador de error; señales de error y realimentación; elementos de medición, características y variables componentes de las transferencias presentes en el sistema ; características de la respuesta; perturbaciones externas e internas a considerar; características y tipo de error; caracterización de la estabilidad; ley de control y tipo de actuación utilizada; relación entre señales analógicas y discretas / digitales; carga/s asociadas al sistema).

El trabajo deberá incluir un programa confeccionado en **lenguaje de alto nivel a elección**, que permita simular y verificar en tiempo real la funcionalidad del sistema mediante la interrelación de las señales / variables del mismo.

IMPORTANTE: Tal lo explicitado en clase, no se solicita la descripción genérica del sistema controlado sino la identificación y descripción de su estructura.

En definitiva, **“encontrar” la totalidad de los contenidos y conceptos trabajados y estudiados desde el dominio de la teoría de control.**

- ✓ Descripción, **desarrollo y fundamentación de la propuesta**: debe ser clara, recomendándose técnicas de escritura conceptual y gráfica.
- ✓ Conclusión: A modo de conclusión, establecer la necesidad y ventajas comparativas del sistema de control propuesto. Es importante incluir opiniones propias en cuanto a posibles mejoramientos, limitaciones analíticas, etc., que permitan establecer un cierto **criterio ingenieril** desde la perspectiva del equipo de trabajo.
- ✓ Consideraciones **especiales**: si aplica, indicar.
- ✓ Bibliografía: citar libros, documentos de texto y fotográficos, folletos de dispositivos transductores, actuadores, sitios web y papers consultados.

Drando. Omar Civale

Introducción	5
Objetivos	5
Objetivos específicos	5
Alcance	6
Elemento de medición y convertidor	6
Variable Controlada	6
Variable de Referencia	6
Elemento de Comparación	7
Señal de Error	7
Elemento de Control	7
Elemento de Corrección	7
Proceso	7
Tipo de Control	8
Perturbaciones	8
Función de Transferencia del Sistema	8
Error en estado Estable	9
Diagrama	9
Desarrollo y fundamentación de la propuesta	9
Bibliografía	9

Introducción

El trabajo involucra a la orquestación de contenedores y el escalado automático de microservicios. En los últimos años, las aplicaciones dejaron de desplegarse sobre servidores de capacidad fija para hacerlo sobre infraestructura elástica gestionada por orquestadores, en la que la capacidad de cómputo asignada a cada servicio se ajusta dinámicamente según la carga que recibe. Esta capa de orquestación puede ejecutarse tanto sobre nubes públicas (Amazon Web Services, Google Cloud, Microsoft Azure) como sobre infraestructura propia on-premise, ya que el mecanismo de escalado opera sobre el cluster con independencia de dónde esté alojado.

Dentro de ese mercado, las arquitecturas de microservicios descomponen una aplicación en servicios pequeños e independientes, cada uno desplegado en múltiples réplicas o pods. La demanda sobre cada servicio es variable (picos de tráfico, horarios de mayor uso, campañas) y mantener una buena experiencia al usuario exige que el tiempo de respuesta se conserve dentro de límites aceptables. Ese tiempo de respuesta, la latencia, es una de las principales métricas de calidad de servicio (QoS), y sostenerla estable frente a una carga cambiante es precisamente un problema de control automático: medir, comparar contra un objetivo y corregir la capacidad disponible.

Es en este punto donde el escalado automático aparece como una solución de mercado consolidada. En lugar de dimensionar la infraestructura para el peor caso, lo que implica recursos ociosos y costos innecesarios, o de ajustarla manualmente, lento y propenso a errores, el sistema regula la cantidad de réplicas en tiempo real en función de la métrica observada.

Objetivos

El objetivo de control es mantener la latencia de respuesta de un microservicio dentro de un umbral deseado, definido por el usuario, de forma automática y frente a una demanda variable.

Objetivos específicos

- Identificar las variables de entrada, salida y perturbación del sistema.
- Representar el proceso mediante un diagrama de bloques con realimentación.
- Modelar el comportamiento dinámico del microservicio y de su controlador PI mediante funciones de transferencia.
- Simular el funcionamiento del lazo ante distintos niveles de carga y evaluar su respuesta frente a picos de tráfico.

Alcance

El trabajo se centra en el análisis y la representación del sistema de control de latencia de un microservicio mediante escalado automático de réplicas, considerando su estructura funcional, sus componentes y su comportamiento dinámico frente a perturbaciones. El desarrollo abarca el modelado conceptual del lazo cerrado, la identificación de cada elemento de control, las funciones de transferencia del proceso y del controlador, el análisis del tipo de sistema, el error en estado estable, y la simulación teórica de la respuesta. Quedan fuera del alcance la implementación real del cluster, la configuración concreta del orquestador y del adaptador de métricas, los aspectos de red y seguridad, el código interno del microservicio y el análisis de costos o facturación. No se aborda tampoco el escalado vertical (aumento de recursos por réplica), ya que el sistema considerado opera por escalado horizontal (variación de la cantidad de pods).

Elemento de medición y convertidor

Sistema de monitoreo Prometheus. Mide la latencia de respuesta del microservicio y la expone como una métrica numérica muestreada a intervalos regulares. Cumple el rol de sensor y de conversión de la magnitud temporal a una señal digital procesable por el lazo.

Fórmula

$$f(t) = L(t) + n(t)$$

donde $L(t)$ es la latencia real y $n(t)$ el ruido de medición.

Unidad

Milisegundos [ms].

Banda de error

El ruido de medición $n(t)$ introduce una variación de ± 5 ms alrededor del valor real, asociada al jitter del muestreo y a la ventana de promediado de Prometheus.

Variable Controlada

La latencia de respuesta del microservicio $L(t)$. Es la magnitud física que el sistema busca mantener estable. Representa el tiempo transcurrido entre que un cliente envía una solicitud y recibe la respuesta. Su valor depende de la relación entre la capacidad instalada (pods) y la demanda recibida (requests/s).

Fórmula

$$\theta_o(t) = L(t)$$

Unidad

Milisegundos [ms].

Banda de error

El sistema se considera en régimen permanente satisfactorio cuando:

$$|L(t) - L_{ref}(t)| \leq 30ms$$

Variable de Referencia

La latencia objetivo definida por el operador. Por ser un valor constante fijado por configuración, la entrada al sistema es un escalón.

Fórmula

$$\theta_i(t) = L_{ref}$$

Unidad

Milisegundos [ms].

Valor de referencia

$$L_{ref} = 200ms$$

Elemento de Comparación

Compara la latencia objetivo con la medida por Prometheus y genera la señal de error. Está implementado dentro de la lógica del autoescalador. Cómo agregar pods reduce la latencia, el lazo cierra como realimentación negativa.

Fórmula

$$e(t) = \theta_i(t) - f(t)$$

Unidad

Milisegundos [ms].

Banda de Error

El error admisible en régimen permanente es $|e(t)| \leq 30ms$.

Señal de Error

Es la salida del comparador y la entrada al controlador. Su signo indica el sentido de la corrección: positivo cuando $L(t) < L_{ref}(t)$ (hay holgura para reducir réplicas); negativo cuando $L(t) > L_{ref}(t)$ (hay que escalar).

Fórmula

$$e(t) = L_{ref} - f(t)$$

Unidad

Milisegundos [ms].

Banda de Error

El error admisible en régimen permanente es $|e(t)| \leq 30ms$.

Elemento de Control

Controlador Proporcional Integral (PI). La parte proporcional reacciona al error instantáneo; la parte integral acumula el error en el tiempo y elimina el error residual en estado estable. No se incorpora acción derivativa porque la latencia medida presenta ruido propio del muestreo: la derivada amplificaría esas variaciones bruscas provocando escalados innecesarios. La salida del controlador es la cantidad deseada de pods.

Kp: Indica cuántos pods agrega o quita el controlador por cada milisegundo de error instantáneo.

Ki: Indica cuántos pods agrega o quita el controlador por cada milisegundo de error acumulado en el tiempo.

Fórmula

$$u(t) = Kp * e(t) + Ki \int_0^t e(t) dt$$

Unidad

La salida $u(t)$ está expresada en pods [pod].

Las ganancias tienen unidades:

- Kp [pod/ms]
- Ki [pod/(ms*s)]

Valor de referencia

Valores de diseño adoptados para la simulación:

- $Kp=0,1$ pod/ms
- $Ki=0,025$ pod/(ms*s)

Banda de error

La salida del controlador está acotada físicamente por los límites del actuador:

$1 \leq u(t) \leq N$ siendo 50 para este caso.

Fuera de este rango el lazo entra en saturación.

Elemento de Corrección

Actuador: Kubernetes ejecutando la decisión del controlador. Crea, elimina o mantiene pods para modificar efectivamente la capacidad disponible del microservicio. Se adopta ganancia unitaria ($Ka = 1$) porque la salida del controlador ya está expresada en pods: Kubernetes despliega exactamente las réplicas que el controlador determina, sin amplificación ni conversión de unidades. El único efecto dinámico del actuador, el cold start, se incorpora a la constante de tiempo T del proceso.

Fórmula

$$a(t) = Ka * u(t)$$

Unidad

Pods [pod].

Banda de error

La salida está saturada en el rango [1,50] pods. Fuera de este rango el actuador opera en saturación.

Perturbaciones

Externa: la variación de la carga (cambios en requests/s), modelada como una entrada escalón que actúa sobre el proceso a través de la misma dinámica de primer orden. Un pico de tráfico se modela como un escalón adicional Δd sobre esa carga nominal. K_d expresa cuántos ms de latencia produce cada req/s adicional sobre la carga base.

Internas: el ruido de medición $n(t)$ (jitter del muestreo), que entra por la realimentación.

Fórmula

Componente de perturbación ante un escalón de carga Δd :

$$Lp(t) = K_d * \Delta d (1 - e^{-t/T})$$

$$\Delta d(t) = D(t) - D(t - T_{scrape})$$

Unidad

- Δd : [req/s].
- K_d : ms·s/req.

Valor de referencia

$$K_d = 0,5 \text{ ms} \cdot \text{s/req}$$

Proceso

El microservicio desplegado. Su latencia responde a la relación entre la capacidad instalada (pods) y la demanda (requests/s). Ante un cambio de réplicas, la latencia se ajusta con una constante de tiempo T asociada al período de scraping de Prometheus, al ciclo de reconciliación del HPA y al tiempo de arranque de los pods.

T_{scrape} : Período de muestreo de la métrica, cada cuánto Prometheus consulta (scrapea) la latencia del microservicio. Hasta que no llega la próxima muestra, el controlador trabaja con un dato viejo.

$T_{reconcile}$: Ciclo de reconciliación del autoescalador, cada cuánto el HPA evalúa la métrica contra el objetivo y calcula cuántos pods debería haber. Actúa en el próximo ciclo.

$T_{coldstart}$: Tiempo de arranque de un pod. Desde que se ordena crear el pod hasta que está listo para atender tráfico: descargar la imagen, levantar el contenedor, inicializar la aplicación, pasar el readiness check.

Fórmula

Respuesta ante un escalón de Δu pods:

$$L(t) = L(t - T_{scrape}) + K * \Delta u (1 - e^{-t/T}) + Lp(t)$$

Siendo $T = T_{scrape} + T_{reconcile} + T_{coldstart}$, K es la ganancia estática del proceso representa cuántos milisegundos varía la latencia en régimen permanente por cada pod que se agrega o se quita y Δu cambio en la cantidad de pods que ordena el controlador en un instante dado.

$$\Delta u = u(t) - u(t - T_{scrape})$$

Unidad

- K [ms/pod]
- T [s]
- $L(t)$ [ms]

Valor de referencia

K : 10 ms/pod

T_{scrape} : El valor por defecto es de 60s, pero para la simulación se adopta como valor: 15 s.

$T_{reconcile}$: Valor por defecto en Kubernetes: 15 s.

$T_{coldstart}$: Es más variable: 30 s para este caso. Es constante porque los pods arrancan en paralelo.

Banda de error

La respuesta del proceso se establece en $5\tau=300s$ para alcanzar el 99% del valor final. Durante ese intervalo la latencia va a estar en estado transitorio.

Tipo de Control

Control PI en lazo cerrado con realimentación continua. La acción integral agrega un integrador al lazo, por lo que el sistema es de tipo 1.

Se adopta un controlador PI porque la acción proporcional permite responder al error instantáneo de latencia, mientras que la acción integral elimina el error residual en estado estable.

No se incorpora acción derivativa como parte principal del controlador, ya que la latencia medida puede presentar jitter y retardos propios del muestreo, la ventana de métricas y el arranque de pods. En este contexto, la acción derivativa podría amplificar variaciones bruscas de la medición y provocar oscilaciones o escalados innecesarios.

Función de Transferencia del Sistema

Proceso

$$G(s) = \frac{K}{TS + 1}$$

Perturbación del proceso

$$G_d(s) = \frac{k_d}{TS + 1}$$

Controlador PI

$$C(s) = k_p + \frac{k_i}{s} = \frac{k_p s + k_i}{s}$$

Actuador

$$A(s) = k_a$$

Transferencia Directa:

$$G_t(s) = \frac{k_a k(k_p s + k_i)}{s(TS + 1)}$$

Error en estado Estable

El controlador PI aporta acción integral ($K_i > 0$), lo que eleva el sistema al tipo 1. Para un sistema tipo 1 con entrada escalón, el error en estado estable es nulo.

$$e_{ss} = \lim_{t \rightarrow \infty} e(t) = \lim_{S \rightarrow 0} S * \frac{1}{1 + \frac{k_a k(k_p s + k_i)}{s(TS + 1)}} * Lref$$

Estabilidad

La estabilidad se analiza sobre la función de transferencia en lazo cerrado $T(s)$, obtenida aplicando álgebra de bloques al diagrama con realimentación unitaria ($H = 1$):

$$G_t(s) = \frac{k_a k(k_p s + k_i)}{s(TS + 1)} \rightarrow T(s) = \frac{\frac{k_a k(k_p s + k_i)}{s(TS + 1)}}{1 + \frac{k_a k(k_p s + k_i)}{s(TS + 1)}}$$


Sustituyendo los valores numéricos ($K_a = 1$, $K = 10$, $K_p = 0,1$, $K_i = 0,025$, $\tau = 60$):

$$T(s) = \frac{\frac{s + 0,25}{s(60s + 1)}}{1 + \frac{s + 0,25}{s(60s + 1)}} = \frac{s + 0,25}{60s^2 + 2s + 0,25}$$

El polinomio característico del sistema es el denominador de $T(s)$: $60s^2 + 2s + 0,25$.

Análisis por coeficientes (criterio de Routh-Hurwitz): los tres coeficientes son positivos y ninguno es cero. Para un polinomio de segundo grado, esta condición es necesaria y suficiente para garantizar la estabilidad.

Diagrama



Desarrollo y fundamentación de la propuesta

Aplicación al marco de control

En el sistema de escalado de pods se busca mantener la latencia del microservicio lo más cercana posible al valor nominal, definido como el valor ideal de latencia en ms establecido por configuración. Sin embargo, la nominalidad es solo un concepto que aplica en sistemas ideales. En la realidad sabemos que existen perturbaciones que, en este caso, alteran la latencia.

Por estos motivos, el sistema debe realimentarse constantemente, para poder conocer el estado actual de la latencia y poder ajustar la cantidad de pods. Este proceso depende de conocer el estado anterior, es decir, la latencia medida previamente, lo que caracteriza al sistema como de lazo cerrado y de realimentación.

La capa de control trabaja de manera integrada para sostener la nominalidad de la salida, asegurando que la latencia de los pods permanezca lo más cercana posible al valor ideal, a pesar de las perturbaciones externas.

Simulación

Resultados y análisis

Bibliografía

Documentación de Kubernetes:

<https://kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale/>

Documentación de Prometheus:

https://prometheus.io/docs/prometheus/latest/getting_started/

<https://prometheus.io/docs/prometheus/latest/configuration/configuration/>